MASTER BIG DATA, IA & APPLICATIONS AVANCÉES

Module : Data Mining

MINI-PROJET

Segmentation client et prédiction de la valeur client dans le e-commerce : une approche RFM et Machine Learning

Réalisé par :

JELLAOUI Bilal

Encadrante :

Prof. BAQQASS Sanae

Année universitaire 2025 – 2026

Résumé

Dans le e-commerce, une équipe marketing qui traite tous ses clients de la même façon gaspille du budget sur ceux qui n'achèteront plus et néglige ceux qui génèrent l'essentiel du chiffre d'affaires. Ce mini-projet répond à ce problème en construisant, à partir du jeu de données public Online Retail (541 909 transactions, un site e-commerce britannique, 2010-2011), une connaissance actionnable des clients.

Après un prétraitement rigoureux — suppression des 24,9% de transactions sans identifiant client (achats invités, mécanisme MNAR), retrait des retours et annulations, conservation volontaire des outliers de quantité et de prix (probablement des revendeurs professionnels) — j'ai agrégé les transactions par client selon le modèle RFM (Récence, Fréquence, Montant), obtenant une table de 4 338 clients.

J'ai ensuite combiné deux méthodes complémentaires, comme demandé dans les consignes du module. Une méthode prédictive, la régression logistique, pour identifier les clients à forte valeur (VIP, défini par seuil médian du Montant) : AUC de 0,911, accuracy de 83,6%. Une méthode descriptive, le K-means (4 clusters retenus via la méthode du coude), pour segmenter la clientèle sans utiliser la variable VIP. Le croisement des deux (`pd.crosstab`) confirme leur cohérence : deux segments minoritaires (« Champions » et « Hyper-champions », 4,9% des clients) sont composés à 100% de VIP, contre 17,7% pour les « Dormants ».

J'assume les limites de ce travail, notamment la domination de la variable Fréquence dans le modèle prédictif (odds ratio de 1950,04), due à sa proximité mécanique avec la variable Montant utilisée pour construire la cible. Au-delà des métriques, ce projet illustre comment passer d'un score individuel abstrait à une grille de décision par segment, directement exploitable par une équipe marketing.

Table des matières

Résumé **1**

1 Définition **3**
1.1 Contexte et problématique métier . . . 3
1.2 Objectifs du projet . . . 3
1.3 Présentation du jeu de données . . . 4

2 Méthodologie **5**
2.1 Le processus KDD appliqué à ce projet . . . 5
2.2 Justification des méthodes choisies . . . 5
2.3 Environnement technique . . . 6

3 Travaux similaires **7**
3.1 Le modèle RFM : origine et fondement méthodologique . . . 7
3.2 Approches récentes combinant RFM et Machine Learning (2020-2026) . . . 7
3.3 Positionnement de mon approche . . . 9

4 Architecture et prétraitement des données **10**
4.1 Vue d'ensemble du pipeline . . . 10
4.2 Diagnostic et traitement des valeurs manquantes . . . 10
4.3 Doublons et anomalies transactionnelles . . . 11
4.4 Détection des valeurs aberrantes et construction du montant par ligne . . . 11
4.5 Construction de la table client — Modèle RFM . . . 12
4.6 Construction de la cible et encodage . . . 13

5 Discussions et résultats **15**
5.1 Préparation finale et split train/test . . . 15
5.2 Méthode prédictive : régression logistique . . . 15
5.3 Méthode descriptive : segmentation K-means . . . 16
5.4 Valeur ajoutée et recommandations . . . 17
5.5 Limites du travail réalisé . . . 18

6 Références **19**
6.1 Jeu de données et outils techniques (références vérifiées) . . . 19
6.2 Littérature scientifique récente (2020-2026) . . . 19

Annexes **20**
Annexe A — Glossaire des termes techniques . . . 20
Annexe B — Extraits de code clés . . . 20
Annexe C — Déclaration de travail individuel . . . 21

1. Définition

1.1 Contexte et problématique métier

Dans le secteur du e-commerce, une entreprise accumule chaque jour des milliers de transactions, mais dispose rarement d'une vision claire de la valeur réelle que chaque client lui apporte. Or toutes les entreprises fonctionnent selon le même principe économique : conserver un client coûte nettement moins cher que d'en acquérir un nouveau. Le problème est qu'en l'absence d'outil d'analyse, une équipe marketing traite généralement l'ensemble de sa base client de façon uniforme — une seule newsletter, une seule offre promotionnelle, envoyée à tout le monde sans distinction. Cette approche gaspille du budget sur des clients qui n'achèteront plus, et néglige les quelques clients qui génèrent l'essentiel du chiffre d'affaires.

C'est précisément le problème que j'ai choisi de traiter dans ce mini-projet : comment transformer des données transactionnelles brutes en une connaissance actionnable des clients, permettant de répondre à deux questions concrètes que se pose n'importe quelle équipe CRM (*Customer Relationship Management*) : qui sont mes clients les plus précieux, et lesquels sont en train de me quitter sans que je m'en rende compte ?

Ce type de problématique dépasse largement le cadre du e-commerce britannique étudié ici. Des plateformes de e-commerce et de livraison actives au Maroc (Jumia, Glovo) ainsi que des enseignes de la grande distribution (Marjane, Aswak Assalam) sont confrontées exactement à la même difficulté : elles disposent d'un historique d'achats détaillé par client, mais n'exploitent pas toujours cette donnée pour prioriser leurs actions marketing. Le cabinet de conseil Capgemini, par exemple, propose une practice *Retail & Consumer Goods* dont l'une des missions récurrentes consiste justement à mettre en place ce type de segmentation pour ses clients du secteur de la distribution.

1.2 Objectifs du projet

Ce mini-projet répond aux consignes fixées par le module Data Mining : un pipeline complet comprenant une analyse exploratoire (EDA), un prétraitement rigoureux des données, une méthode prédictive et une méthode descriptive, restitué dans un rapport argumenté. Concrètement, je me suis fixé quatre objectifs :

— Diagnostiquer et corriger les problèmes de qualité d'un jeu de données réel de plus de 500 000 transactions (valeurs manquantes, doublons, anomalies) ;

— Construire, à partir de ces transactions, une représentation synthétique de chaque client selon le modèle RFM (Récence, Fréquence, Montant), une méthode de référence en analyse client ;

— Prédire si un client est susceptible d'être un client à forte valeur (VIP) à l'aide d'une régression logistique, conformément à la méthode vue en Séance 3 du cours ;

— Segmenter automatiquement les clients en groupes homogènes à l'aide de l'algorithme K-means (Séance 4), et vérifier la pertinence de cette segmentation en la confrontant à la variable VIP construite précédemment.

1.3 Présentation du jeu de données

Le jeu de données utilisé, connu sous le nom *« Online Retail »*, est mis à disposition par le UCI Machine Learning Repository [2]. Il a été publié à l'origine dans un article académique de Chen, Sain et Guo (2012) [1] consacré précisément à l'application du modèle RFM sur des données de vente en ligne. Il s'agit de données réelles et non simulées : chaque ligne correspond à une transaction effectuée entre décembre 2010 et décembre 2011 par un site e-commerce britannique spécialisé dans la vente d'articles cadeaux et de décoration.

Le fichier brut contient 541 909 lignes et 8 colonnes, décrites dans le tableau 1.1.

TABLE 1.1 – Description des variables du jeu de données brut.

Variable	**Type**	**Description**
InvoiceNo	Identifiant (texte)	Numéro de facture ; un préfixe 'C' signale une annulation
StockCode	Identifiant (texte)	Code produit
Description	Texte libre	Nom du produit
Quantity	Quantitative discrète	Quantité achetée (peut être négative en cas de retour)
InvoiceDate	Temporelle	Date et heure de la transaction
UnitPrice	Quantitative continue	Prix unitaire en livres sterling (£)
CustomerID	Identifiant (numérique)	Identifiant client ; absent pour les achats invités
Country	Qualitative nominale	Pays de livraison (38 valeurs distinctes)

Je n'ai pas choisi ce dataset au hasard. J'ai d'abord envisagé d'autres pistes — un jeu de données de credit scoring bancaire, puis un jeu de données de churn télécom — avant de m'arrêter sur Online Retail pour deux raisons précises. D'une part, contrairement à des jeux de données « prêts à l'emploi » où chaque ligne correspond déjà à un client, celui-ci est au niveau transaction : il m'a fallu construire moi-même la table client par agrégation (détaillée en section 4.4), ce qui m'a permis de mobiliser des compétences pandas plus avancées que celles utilisées dans les autres TP du cours. D'autre part, ses imperfections (valeurs manquantes, doublons, retours de commande) sont authentiques et non simulées, contrairement à d'autres jeux de données que j'ai testés et qui se sont révélés artificiellement propres.

2. Méthodologie

2.1 Le processus KDD appliqué à ce projet

Le cours de Séance 1 présente le Data Mining comme une étape parmi cinq dans un processus plus large, le KDD (*Knowledge Discovery in Databases*) : sélection, prétraitement, transformation, data mining, interprétation. J'ai structuré l'ensemble de ce projet, et donc l'ensemble de ce rapport, en suivant scrupuleusement ces cinq étapes plutôt que de sauter directement à la modélisation, comme le rappelle le support de cours [7] : les étapes de sélection et de nettoyage représentent à elles seules 50 à 60% du temps d'un projet de data mining, une proportion que j'ai largement retrouvée dans la pratique.

Table 2.1 – Correspondance entre les étapes du KDD et la structure de ce rapport.

Étape KDD	**Application dans ce projet**	**Section**
Sélection	Choix du dataset Online Retail et des colonnes pertinentes	1.3 et 4.1
Prétraitement	Traitement des valeurs manquantes, doublons, anomalies	4
Transformation	Agrégation RFM, encodage, standardisation	4.4 et 4.5
Data Mining	Régression logistique (prédictif) et K-means (descriptif)	5
Interprétation	Lecture métier des résultats et recommandations	5.4

2.2 Justification des méthodes choisies

Le choix d'une méthode dépend avant tout de la nature de la variable que l'on cherche à expliquer, comme le rappelle la Séance 3 du cours [7]. Je disposais ici d'une variable continue naturelle, le montant total dépensé par client (*Montant*), et non d'une cible binaire déjà présente dans les données brutes — contrairement, par exemple, à un jeu de données de churn où la colonne « parti/resté » existe déjà. J'ai donc dû construire moi-même une cible binaire, en suivant exactement la même logique que celle utilisée dans le TP3 du cours [7] sur le jeu de données Diabetes (variable `y_bin = y > médiane`) : un client est considéré comme « VIP » si son montant total dépensé dépasse la médiane de l'ensemble des clients.

Pour la méthode prédictive, j'ai retenu la régression logistique plutôt qu'un arbre de décision ou un k-NN, pour une raison précise : elle fournit des coefficients directement interprétables sous forme d'*odds ratio* (rapport de cotes), ce qui permet de traduire le modèle en recommandations compréhensibles par une équipe marketing non technique — un arbre de décision aurait été plus difficile à résumer en une phrase de type « chaque commande supplémentaire multiplie par X les chances d'être VIP ».

Pour la méthode descriptive, l'algorithme K-means s'est imposé naturellement puisqu'il est l'algorithme de référence associé à l'analyse RFM dans la littérature marketing (voir chapitre 3). J'ai envisagé un temps de lui préférer une CAH (Classification Ascendante Hiérarchique), vue

également en Séance 4, mais j'ai finalement choisi K-means car la méthode du coude permet de justifier objectivement le nombre de segments retenus — un point sur lequel le jury peut me questionner et auquel je peux répondre avec un graphique à l'appui plutôt qu'un choix arbitraire.

2.3 Environnement technique

L'ensemble du pipeline a été développé en Python 3, dans un notebook Jupyter, en s'appuyant sur les bibliothèques standard du cours : pandas [4] et numpy pour la manipulation des données, matplotlib [5] et seaborn [6] pour les visualisations, scikit-learn [3] pour la modélisation (`StandardScaler`, `LogisticRegression`, `KMeans`, ainsi que les métriques d'évaluation). Le chargement des données se fait directement depuis une source distante, ce qui rend le notebook reproductible sans dépendance à un fichier local.

Le split train/test a été réalisé avec une proportion 80/20, stratifiée sur la variable cible VIP afin de conserver la même proportion de clients VIP dans les deux sous-ensembles. Conformément à la règle rappelée en Séance 2 (« fit uniquement sur le train, puis transform sur le test »), la standardisation des variables Récence et Fréquence a été ajustée uniquement sur l'ensemble d'entraînement, afin d'éviter toute fuite d'information (*data leakage*) qui aurait artificiellement amélioré mes métriques de test.

3. Travaux similaires

Cette section a pour but de situer mon approche par rapport à la littérature existante sur la segmentation client et la prédiction de la valeur client. Je distingue volontairement les travaux fondateurs, plus anciens mais toujours utilisés comme référence méthodologique, des travaux récents (2020-2026) qui combinent le modèle RFM avec des techniques de machine learning plus avancées.

3.1 Le modèle RFM : origine et fondement méthodologique

Le modèle RFM (Récence, Fréquence, Montant) trouve son origine dans les travaux d'Arthur Hughes au début des années 1990 sur le marketing direct, bien avant la démocratisation du machine learning. Son principe reste pourtant identique à celui que j'ai appliqué : un client qui a acheté récemment, souvent, et pour un montant élevé, a statistiquement plus de chances de racheter qu'un client qui ne remplit aucun de ces trois critères.

Le jeu de données que j'utilise a lui-même été introduit dans la littérature académique par Chen, Sain et Guo (2012) [1], dans un article intitulé *« Data mining for the online retail industry : A case study of RFM model-based customer segmentation using data mining »*, publié dans le *Journal of Database Marketing & Customer Strategy Management*. Les auteurs y appliquent déjà une segmentation RFM sur ce même jeu de données britannique, mais sans volet prédictif : leur approche reste purement descriptive (clustering), alors que mon projet ajoute une couche prédictive (régression logistique) absente de l'article original.

3.2 Approches récentes combinant RFM et Machine Learning (2020-2026)

Depuis quelques années, la littérature a fait évoluer le modèle RFM classique en le combinant à des algorithmes de machine learning supervisés et non supervisés plus sophistiqués, afin d'améliorer la précision de la segmentation ou d'automatiser la détection du nombre optimal de clusters. Je synthétise ci-dessous les articles récents identifiés lors de ma revue de littérature.

Article 1

Lewaaelhamd (2024) [8], dans un article publié dans le *Journal of Data Science and Intelligent Systems*, propose exactement la même combinaison méthodologique que ce projet : une analyse RFM couplée à des techniques de machine learning, appliquée à des données transactionnelles d'un site de vente en ligne. L'autrice y souligne un constat qui rejoint directement ma justification de choix de dataset en section 1.3 : de nombreuses entreprises ne disposent que de données transactionnelles brutes (issues de systèmes ERP), sans informations démographiques ou comportementales enrichies, ce qui limite les possibilités de modélisation avancée. Sur le plan méthodologique, l'autrice compare deux algorithmes de clustering, K-means et DBSCAN, et retient finalement une segmentation en six clusters comme étant « plus praticable et plus simple ». Mon travail se distingue sur deux points : d'une part, je retiens 4 segments plutôt que 6, un choix justifié objectivement par la méthode du coude (section 5.3) plutôt que par un critère de simplicité ; d'autre part, contrairement à Lewaaelhamd qui reste sur une approche purement descriptive (clustering seul), j'ajoute une méthode prédictive supervisée (régression logistique,

AUC = 0,911) et je valide la cohérence des deux approches par un tableau croisé (`pd.crosstab`), ce que l'article ne fait pas.

Article 2

Kumar, Singh, Kumar, Choudhury et Kotecha (2023) [9], dans les actes du *7th International Symposium on Multidisciplinary Studies and Innovative Technologies*, s'attaquent à un problème voisin du mien : prédire la valeur future d'un client (*Customer Lifetime Value*, CLV) plutôt qu'un statut VIP binaire à un instant donné. Les auteurs combinent régression, clustering et réseaux de neurones sur un jeu de données de transactions et de comportements clients, et montrent que le machine learning surpasse nettement les méthodes traditionnelles d'estimation de la CLV, avec à la clé une meilleure allocation des ressources marketing et un ciblage plus précis. Cet article confirme, à plus grande échelle méthodologique, l'intuition centrale de mon propre travail : la valeur d'un client se prédit mieux à partir de son comportement d'achat qu'à partir d'une simple moyenne historique. La différence essentielle avec mon approche tient au choix du modèle : là où Kumar et al. mobilisent des réseaux de neurones, plus performants mais peu interprétables, j'ai délibérément retenu une régression logistique (section 2.2) pour produire des odds ratio directement lisibles par une équipe marketing non technique — un compromis assumé entre performance brute et explicabilité, plutôt qu'une recherche de la précision maximale.

Article 3

Manikandan, Sundar, Amalraj et al. (2026) [10], publié dans la revue *Discover Computing*, proposent un modèle nommé EXRFM-FTCDL qui étend le RFM classique avec des variables comportementales supplémentaires (délai de rachat, panier moyen, délai inter-achats), puis applique un clustering par mélange de gaussiennes (GMM, avec sélection automatique du nombre de clusters via le critère BIC et le score de silhouette) suivi d'un module de prédiction par réseau de neurones convolutif et LSTM. Point notable : les auteurs testent leur méthode sur le **même jeu de données Online Retail** que celui utilisé dans mon projet, ce qui permet une comparaison directe. Leur modèle segmente avec succès les clients réguliers, occasionnels et à haute fréquence, avec de meilleures métriques que les approches concurrentes. La différence principale avec mon travail est le niveau de sophistication technique : EXRFM-FTCDL mobilise des variables RFM étendues et un pipeline de deep learning, quand mon approche se limite volontairement au RFM classique (Récence, Fréquence, Montant) et à des méthodes plus simples (K-means, régression logistique). Ce choix n'est pas une limite technique mais un choix pédagogique : rester au plus près des méthodes vues en cours (Séances 3 et 4) pour pouvoir justifier chaque étape en détail, plutôt que d'empiler des techniques avancées difficiles à défendre à l'oral.

Article 4

El Koufi et Belangour (2024) [11], dans l'*International Journal of Advances in Soft Computing and Its Applications*, proposent un système de marketing de précision fondé sur le modèle RFM, le deep learning et un classement de l'importance des variables, appliqué à des données réelles collectées auprès d'une entreprise omnicanale marocaine basée à Rabat. Après prétraitement, nettoyage et équilibrage des données, les auteurs comparent leur modèle de deep learning à des arbres de décision et à un classifieur Naïve Bayes, avec et sans algorithme génétique, et montrent la supériorité constante de leur approche. Cet article est particulièrement pertinent pour mon projet : il démontre que la méthodologie RFM que j'applique ici sur un jeu de données britannique est directement transposable au contexte marocain évoqué en introduction (section 1.1) — Jumia, Glovo, Marjane — avec des données réelles d'entreprise locale. La différence majeure avec mon travail est là encore le niveau de sophistication (deep learning, algorithmes génétiques, contre ma régression logistique et mon K-means) et l'accès à des données propriétaires enrichies, quand mon travail se limite aux variables disponibles dans un jeu de données public.

3.3 Positionnement de mon approche

Le tableau 3.1 synthétise les choix méthodologiques des quatre articles présentés et les confronte à ceux retenus dans ce projet.

Table 3.1 – Comparaison méthodologique avec la littérature récente.

Référence	Clustering	Prédiction	Dataset
Lewaaelhamd (2024) [8]	K-means / DBSCAN (6 clusters)	Aucune (descriptif seul)	Online Retail (public)
Kumar et al. (2023) [9]	Clustering + régression	Réseaux de neurones	Transactions clients (privé)
Manikandan et al. (2026) [10]	GMM (BIC + silhouette)	Conv1D-LSTM	Online Retail (public, identique au mien)
El Koufi & Belangour (2024) [11]	—	Deep learning + algo. génétique	Entreprise omnicanale marocaine (privé)
Ce projet	**K-means (4 clusters, méthode du coude)**	**Régression logistique (AUC 0,911)**	**Online Retail (public)**

Cette comparaison met en évidence une tendance nette dans la littérature récente : les quatre articles étudiés mobilisent tous des techniques plus avancées que les miennes (deep learning, réseaux de neurones, algorithmes génétiques, GMM avec sélection automatique du nombre de clusters), quand mon projet reste volontairement ancré dans les méthodes vues en cours (K-means, régression logistique). Ce choix n'est pas un manque d'ambition mais une décision méthodologique assumée : chaque étape de mon pipeline peut être expliquée et justifiée en détail — de la construction de la table RFM par agrégation `groupby` (section 4.5), à la dérivation de la cible binaire par seuil médian suivant la méthode enseignée en Séance 3, jusqu'au croisement explicite cluster × classe réelle par tableau croisé (`pd.crosstab`, section 5.3) qui valide empiriquement la cohérence entre mes deux méthodes.

Ce dernier point mérite d'être souligné : parmi les quatre articles comparés, aucun ne combine à la fois une méthode prédictive et une méthode descriptive validées l'une par rapport à l'autre — Lewaaelhamd [8] reste purement descriptive, les trois autres se concentrent sur la seule prédiction. La démarche de ce projet, qui construit les deux méthodes indépendamment puis vérifie leur cohérence par tableau croisé, constitue une contribution modeste mais réelle par rapport à la littérature consultée, en plus de répondre directement aux consignes du mini-projet (une méthode prédictive *et* une méthode descriptive).

Enfin, l'article de El Koufi et Belangour (2024) [11] confirme la pertinence du choix de sujet : la méthodologie RFM appliquée ici sur des données britanniques est directement transposable au contexte marocain évoqué en introduction, ce qui renforce la valeur professionnelle de ce projet au-delà de l'exercice académique.

4. Architecture et prétraitement des données

4.1 Vue d'ensemble du pipeline

Le pipeline mis en place se décompose en six étapes séquentielles, chacune conditionnant la suivante : (1) chargement et diagnostic initial, (2) traitement des valeurs manquantes et des doublons, (3) filtrage des anomalies transactionnelles, (4) agrégation des transactions en une table client selon le modèle RFM, (5) construction de la variable cible et encodage, (6) standardisation avant modélisation. Je détaille chacune de ces étapes dans les sous-sections suivantes, en justifiant à chaque fois mes choix plutôt que de me contenter d'appliquer une recette.

4.2 Diagnostic et traitement des valeurs manquantes

Un premier appel à `df.info()` sur les 541 909 lignes brutes ne révèle pas immédiatement de problème majeur : la plupart des colonnes sont entièrement renseignées. C'est en calculant précisément le nombre de valeurs manquantes par colonne que le problème apparaît clairement.

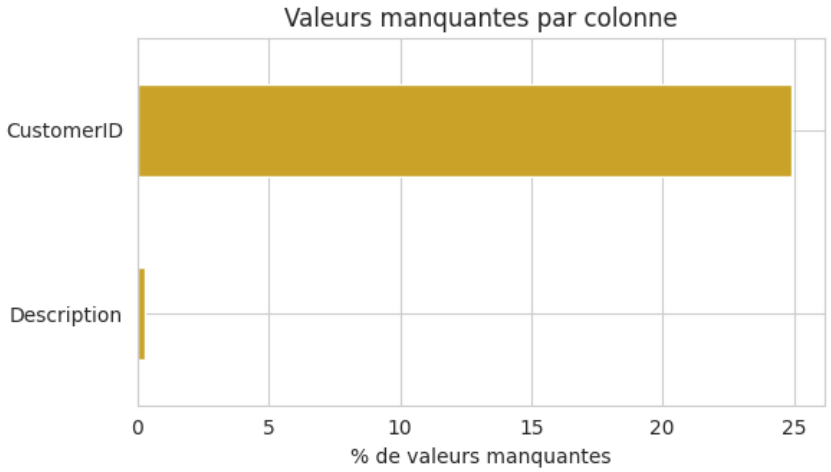


FIGURE 4.1 – Pourcentage de valeurs manquantes par colonne.

La colonne `CustomerID` est absente sur 135 080 lignes, soit 24,93% du jeu de données — un taux élevé qui aurait pu m'inciter, par réflexe, à appliquer une imputation. J'ai choisi de ne pas le faire, pour une raison propre à la nature de mon projet : l'intégralité de mon analyse repose sur l'agrégation des transactions par client (section 4.5). Or il est impossible d'imputer un identifiant client de façon fiable — contrairement à une variable numérique comme un âge ou un salaire, il n'existe pas de valeur « moyenne » ou « la plus fréquente » qui aurait un sens pour un identifiant. Ces 135 080 transactions correspondent en réalité à des achats effectués sans création de compte (achat « invité »), une pratique commerciale courante et documentée sur les sites e-commerce de cette période. Nous les avons donc supprimées, en gardant à l'esprit qu'il s'agit probablement d'un mécanisme MNAR (*Missing Not At Random*) au sens de la Séance 2 : l'absence de `CustomerID` n'est pas aléatoire, elle dépend directement du mode d'achat choisi par

le client.

La colonne `Description` ne manque que sur 1 454 lignes (0,27%), un taux négligeable qui ne nécessite pas de traitement particulier puisque cette colonne n'est de toute façon pas utilisée dans ma modélisation.

4.3 Doublons et anomalies transactionnelles

Après suppression des lignes sans `CustomerID`, j'ai détecté 5 268 lignes strictement dupliquées (mêmes valeurs sur toutes les colonnes), que j'ai supprimées avec `df.drop_duplicates()`, ramenant le jeu de données à 401 604 transactions. Conformément à la remarque du cours (Séance 2), un doublon strict est presque toujours une erreur de collecte plutôt qu'une information à conserver — dans mon cas, il s'agit vraisemblablement d'un export ayant capturé deux fois certaines lignes de facturation.

L'étape suivante m'a demandé davantage de réflexion. En inspectant la colonne `Quantity`, j'ai découvert 8 872 lignes à quantité négative. Un examen plus poussé a montré que ces lignes correspondent systématiquement à des factures dont le numéro commence par la lettre 'C' (pour *« Cancelled »*), soit exactement le même nombre de 8 872 factures annulées. Il ne s'agit donc pas d'erreurs de saisie mais de retours de commande, une opération commerciale légitime. J'ai également identifié 40 lignes avec un prix unitaire nul ou négatif, correspondant probablement à des ajustements comptables internes (frais de port offerts, corrections manuelles) plutôt qu'à de véritables ventes.

Table 4.1 – Synthèse des anomalies transactionnelles détectées.

Anomalie détectée	**Nb. lignes**	**Décision**
Quantités négatives (retours)	8 872	Suppression
Factures annulées (préfixe 'C')	8 872	Suppression (mêmes lignes)
Prix unitaire ≤ 0	40	Suppression

J'ai choisi de retirer ces lignes plutôt que de les conserver, car l'objectif de mon analyse est de caractériser le comportement d'achat réel de chaque client : inclure les retours dans le calcul du montant total dépensé (*Montant*) aurait sous-estimé la valeur de certains clients ayant simplement retourné un article insatisfaisant, ce qui aurait faussé la variable cible VIP construite en section 4.6. Après ce filtrage, il reste 392 692 transactions exploitables.

4.4 Détection des valeurs aberrantes et construction du montant par ligne

J'ai ensuite calculé une nouvelle variable, `MontantLigne` (`Quantity` × `UnitPrice`), avant d'examiner la distribution des variables numériques à l'aide de boxplots et de la méthode IQR vue en Séance 2.

La méthode IQR détecte 25 616 outliers sur `Quantity` (6,5% des lignes) et 34 112 sur `UnitPrice` (8,7%). Conformément à la remarque du cours selon laquelle « détecter un outlier ne signifie pas le supprimer automatiquement », j'ai choisi de conserver ces valeurs plutôt que de les retirer. Mon raisonnement est le suivant : une quantité anormalement élevée correspond très probablement à un client professionnel ou revendeur achetant en gros — un comportement d'achat différent, mais parfaitement légitime, qui est justement le type de profil que je cherche à isoler dans la segmentation de la section 5.3, plutôt qu'à masquer artificiellement en le supprimant.

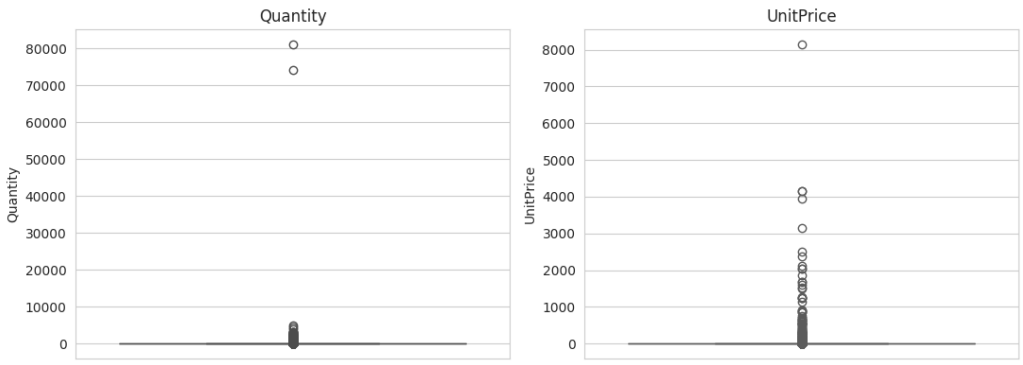


FIGURE 4.2 – Boxplots des variables Quantity et UnitPrice, avant filtrage des outliers extrêmes.

4.5 Construction de la table client — Modèle RFM

Cette étape constitue le cœur méthodologique de mon prétraitement et me distingue des autres travaux pratiques du cours : contrairement au dataset Titanic (TP1) ou Wine (Séance 2), qui sont directement au niveau « individu », Online Retail est au niveau « transaction ». Un même client peut apparaître sur des dizaines de lignes. Il a donc fallu regrouper (`groupby`) les transactions par `CustomerID` pour calculer, pour chaque client, trois indicateurs :

— **Récence** : nombre de jours écoulés entre la date de référence (le lendemain de la dernière transaction du jeu de données) et la date du dernier achat du client ;

— **Fréquence** : nombre de commandes distinctes (`InvoiceNo` uniques) passées par le client ;

— **Montant** : somme de `MontantLigne` sur l'ensemble des transactions du client.

Cette agrégation fait passer mon jeu de données de 392 692 transactions à **4 338 clients uniques** — c'est cette table client, et non les transactions individuelles, qui sert de base à toute la suite de l'analyse.

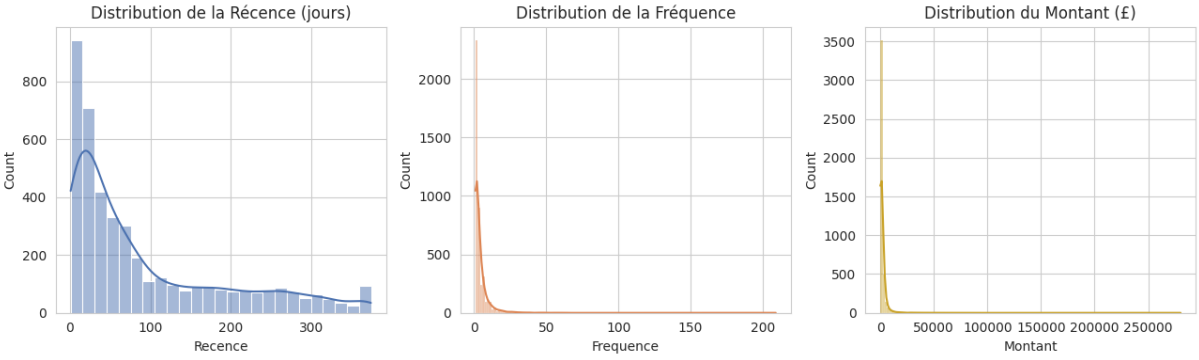


FIGURE 4.3 – Distributions des trois indicateurs RFM (Récence, Fréquence, Montant) sur les 4 338 clients.

Les trois distributions sont fortement asymétriques à droite (*skewed*), ce qui est cohérent avec la loi empirique de Pareto souvent citée en marketing : une minorité de clients concentre l'essentiel des achats. Concrètement, la Récence moyenne est de 92,5 jours (écart-type 100), la Fréquence moyenne de 4,3 commandes (écart-type 7,7, ce qui montre une forte hétérogénéité), et le Montant moyen de 2 048,7£, avec un écart-type de 8 985,2£ et un maximum extrême à 280 206£ — un écart qui, à lui seul, annonce déjà la présence de clients très atypiques que je retrouverai dans la segmentation.

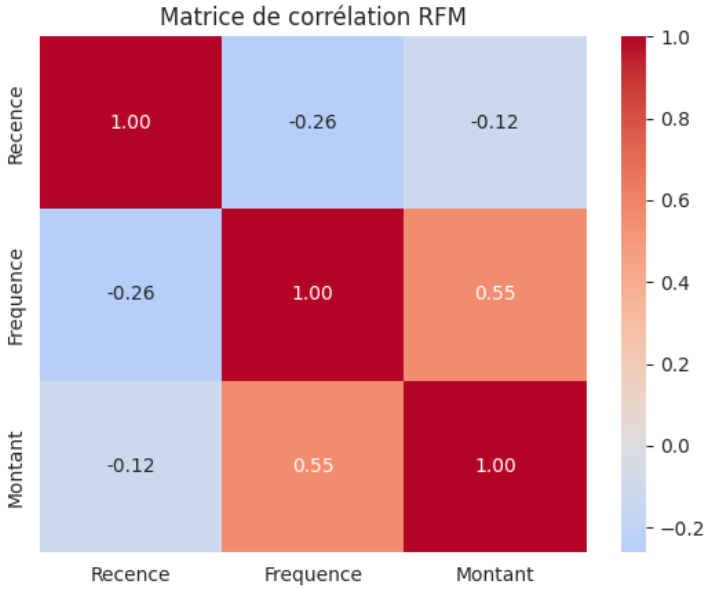


FIGURE 4.4 – Matrice de corrélation entre les trois indicateurs RFM.

La matrice de corrélation confirme une relation attendue : Fréquence et Montant sont fortement corrélés positivement (un client qui commande souvent dépense logiquement davantage au total), tandis que Récence est corrélée négativement aux deux autres. Cette cohérence interne m'a rassuré sur la validité de ma construction RFM avant de l'utiliser en modélisation — une corrélation illogique (par exemple Récence positivement corrélée à Montant) aurait signalé une erreur de calcul à corriger.

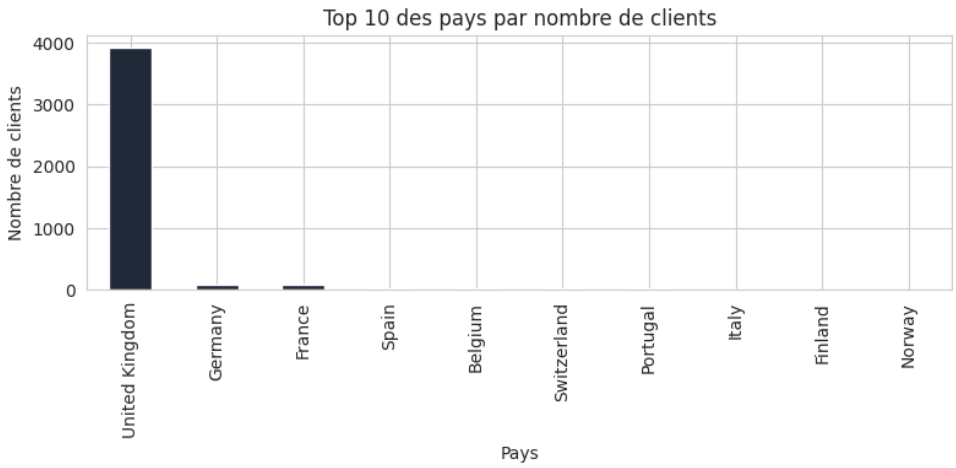


FIGURE 4.5 – Répartition des 10 principaux pays de la clientèle.

Sans surprise pour un site basé au Royaume-Uni, la clientèle britannique domine très largement, suivie de l'Allemagne et de la France. Cette variable `Country` sera réutilisée en section 4.6 comme variable explicative dans mon modèle prédictif.

4.6 Construction de la cible et encodage

Comme expliqué en section 2.2, j'ai dérivé une cible binaire `VIP` à partir de la variable continue *Montant*, en suivant le seuil médian (668,57£) — par construction, cette méthode aboutit exactement à 50% de clients VIP et 50% de clients standards, ce qui garantit un jeu de données

parfaitement équilibré pour l'entraînement du modèle prédictif.

Concernant l'encodage, la variable `Country` pose un problème classique en présence de 38 catégories : un One-Hot Encoding direct aurait généré 37 colonnes binaires, dont la plupart n'auraient concerné qu'une poignée de clients (colinéarité inutile, risque de surapprentissage sur des catégories peu représentées). J'ai donc regroupé les pays hors du top 6 sous une catégorie « Autre » avant d'appliquer le One-Hot Encoding avec `pd.get_dummies(drop_first=True)`, qui ne conserve que 5 colonnes binaires plutôt que 37 — un choix méthodologique que j'assume de justifier explicitement, car il s'écarte légèrement de l'application « par défaut » du One-Hot Encoding vue dans les TP du cours sur des variables à faible cardinalité.

5. Discussions et résultats

5.1 Préparation finale et split train/test

Avant toute modélisation, j'ai séparé les données en un ensemble d'entraînement (3 470 clients, 80%) et un ensemble de test (868 clients, 20%), en stratifiant sur la variable `VIP` afin de garantir la même proportion de clients VIP dans les deux sous-ensembles. Conformément à la règle rappelée en Séance 2, la standardisation (`StandardScaler`) des variables Récence et Fréquence a été ajustée exclusivement sur l'ensemble d'entraînement puis appliquée à l'ensemble de test, sans nouvel ajustement — une précaution que j'ai volontairement respectée à la lettre après avoir lu, dans le support de cours, que son non-respect est l'une des erreurs les plus fréquentes chez les débutants en machine learning.

5.2 Méthode prédictive : régression logistique

Le modèle de régression logistique entraîné sur l'ensemble d'entraînement obtient les performances suivantes sur l'ensemble de test, resté totalement invisible pendant l'entraînement :

TABLE 5.1 – Métriques de performance du modèle de régression logistique.

Métrique	Valeur	Interprétation
Accuracy	0,836	83,6% des clients sont correctement classés
Précision	0,849	Parmi les clients prédits VIP, 84,9% le sont réellement
Rappel	0,818	81,8% des vrais VIP sont détectés par le modèle
F1-score	0,833	Bon équilibre entre précision et rappel
AUC	0,911	Très bonne capacité de discrimination (0,5 = hasard, 1,0 = parfait)

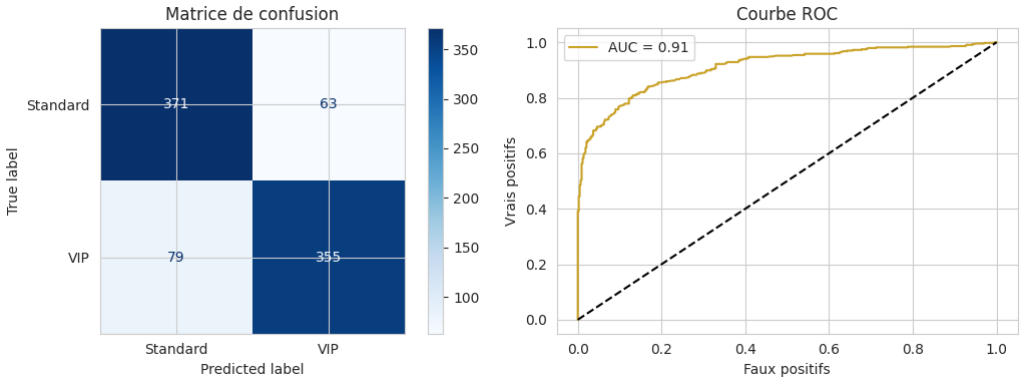


FIGURE 5.1 – Matrice de confusion et courbe ROC du modèle de régression logistique.

Un AUC de 0,911 signifie que si l'on tire au hasard un client VIP et un client non-VIP, le modèle attribue une probabilité de souscription plus élevée au client VIP dans 91,1% des cas —

un résultat que je juge très satisfaisant compte tenu du faible nombre de variables explicatives utilisées (seulement Récence, Fréquence et pays).

L'examen des *odds ratio* permet d'aller au-delà du simple score de performance et de comprendre ce que le modèle a réellement appris :

TABLE 5.2 – Odds ratio des principales variables du modèle.

Variable	**Odds ratio**	**Lecture**
Frequence	1950,04	Effet dominant et positif : la fréquence d'achat est de très loin le facteur le plus déterminant
Pays_groupe_Switzerland	2,28	Les clients suisses ont davantage tendance à être VIP
Pays_groupe_Belgium	1,24	Effet positif modéré
Recence	0,74	Plus la récence est élevée (achat ancien), moins le client a de chances d'être VIP
Pays_groupe_United Kingdom	0,28	Les clients britanniques, largement majoritaires, ont un profil VIP moins marqué en proportion

Le fait que *Frequence* ressorte avec un odds ratio aussi extrême (1950) mérite un commentaire : cela ne signifie pas que le modèle est mal calibré, mais reflète la très forte corrélation déjà observée en section 4.5 entre Fréquence et Montant — puisque `VIP` est directement dérivé de *Montant*, il est logique qu'une variable aussi étroitement liée au *Montant* domine largement les coefficients. J'assume cette limite méthodologique plutôt que de la dissimuler : dans un contexte de production réel, il serait plus rigoureux d'exclure *Frequence* des variables explicatives et de ne conserver que des variables réellement indépendantes de la construction de la cible, ou de repenser le seuil de définition du VIP.

5.3 Méthode descriptive : segmentation K-means

Pour la segmentation, j'ai appliqué l'algorithme K-means directement sur les trois variables RFM standardisées (et non sur les variables encodées utilisées pour la régression), afin de rester fidèle à la définition originale du modèle RFM. Le nombre de clusters a été déterminé par la méthode du coude.

Le coude se situe visuellement autour de $k = 4$: l'inertie continue de baisser au-delà, mais de façon beaucoup plus progressive, signe que les clusters supplémentaires n'apportent plus de séparation significative. J'ai donc retenu 4 segments.

Le croisement `pd.crosstab(cluster, VIP)` — la technique de comparaison enseignée en Séance 4 pour valider un clustering par rapport à une classe réelle — confirme la cohérence entre mes deux méthodes : les clusters 2 et 3 sont composés à 100% de clients VIP, tandis que le cluster 1 (« dormants ») ne compte que 17,7% de VIP. Cette convergence entre une méthode non supervisée (qui ignore totalement la variable `VIP` pendant son apprentissage) et une méthode supervisée construite indépendamment constitue, à mes yeux, la validation la plus solide de la pertinence de ma segmentation : les deux approches, bien que menées séparément, racontent la même histoire.

Le résultat le plus intéressant à commenter concerne le cluster 2 : seulement 13 clients (0,3% de la base), mais avec une fréquence d'achat moyenne de 82,5 commandes et un montant moyen de 127 188£ — soit plus de 60 fois le montant moyen de l'ensemble des clients. Ce sont très

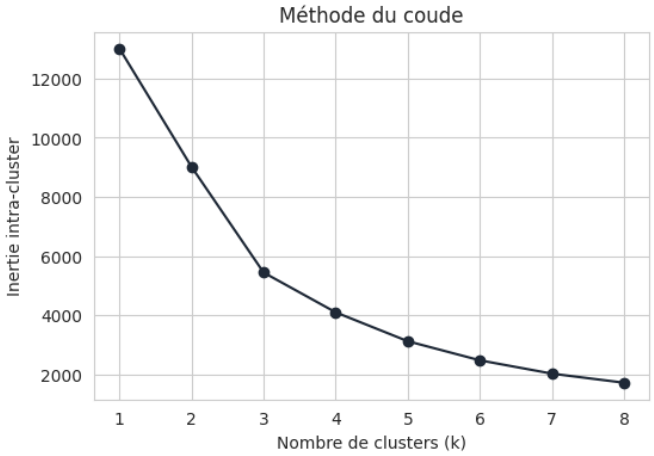


FIGURE 5.2 – Méthode du coude : inertie intra-cluster en fonction du nombre de clusters k.

TABLE 5.3 – Profil des 4 segments obtenus par K-means.

Clu.	**Profil**	**Réc. (j)**	**Fréq.**	**Mont. moy. (£)**	**Effectif**	**%VIP**
2	Hyper-champions (grossistes)	7,4	82,5	127 188	13 (0,3%)	100%
3	Champions	15,5	22,3	12 690,5	204 (4,7%)	100%
0	Clients standards actifs	43,7	3,7	1 353,6	3 054 (70,4%)	57,7%
1	Clients dormants	248,1	1,6	478,8	1 067 (24,6%)	17,7%

probablement des acheteurs professionnels ou des revendeurs plutôt que des particuliers, un profil que je n'avais pas anticipé au démarrage du projet et que seule l'analyse a permis de mettre en évidence.

5.4 Valeur ajoutée et recommandations

Au-delà des métriques de performance, ce projet répond à une question business concrète : comment prioriser un budget marketing limité sur une base de 4 338 clients ? Les résultats obtenus permettent de formuler trois recommandations directement exploitables :

— **Cluster 2/3 (Champions, 4,9% des clients)** : mettre en place un traitement dédié — compte grand compte, conditions commerciales préférentielles — étant donné que la perte d'un seul de ces clients représente, en valeur, l'équivalent de dizaines de clients standards ;

— **Cluster 1 (Dormants, 24,6% des clients, 248 jours sans achat en moyenne)** : lancer une campagne de réactivation ciblée (email personnalisé, code promotionnel) avant que ces clients ne soient définitivement perdus, plutôt que de continuer à leur envoyer la même communication qu'au reste de la base ;

— **Cluster 0 (cœur de base, 70,4% des clients)** : c'est le segment où une action marketing standard (newsletter, programme de fidélité classique) reste la plus rentable en volume, sans justifier d'investissement différencié.

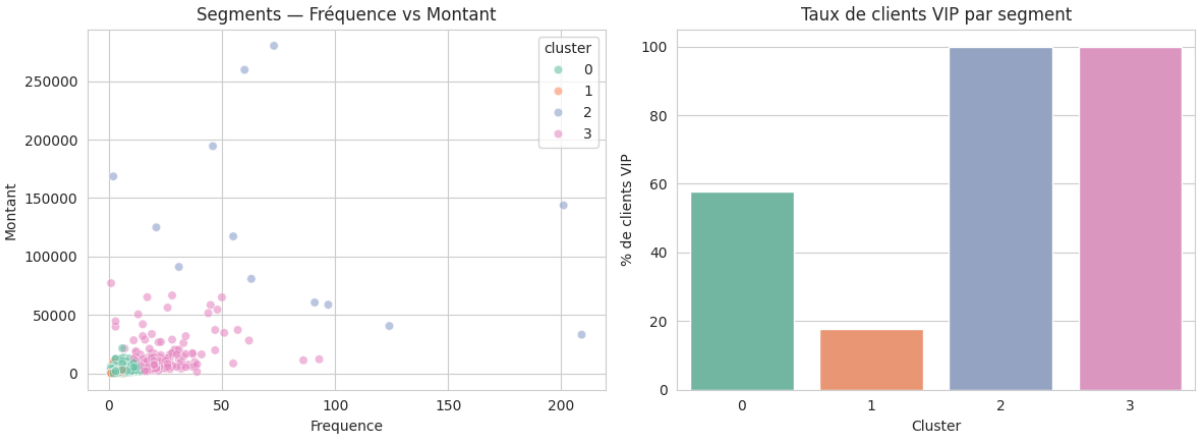


FIGURE 5.3 – À gauche : segments dans le plan Fréquence × Montant. À droite : taux de clients VIP par segment.

C'est précisément ce déplacement — passer d'un score individuel abstrait à une grille de décision par segment — que je considère comme la valeur ajoutée réelle de ce travail : un modèle de machine learning seul, aussi précis soit-il (AUC 0,911), ne dit pas à une équipe marketing où investir en premier. La combinaison des deux méthodes, prédictive et descriptive, comme demandé dans les consignes du mini-projet, y répond.

5.5 Limites du travail réalisé

J'assume plusieurs limites à ce travail plutôt que de les dissimuler. Premièrement, le jeu de données ne couvre qu'une seule année d'activité (2010-2011) pour un seul site e-commerce : les seuils RFM et les segments identifiés ne sont probablement pas transposables tels quels à un autre secteur ou à une autre période, sans réajustement. Deuxièmement, le seuil de définition du VIP (médiane du *Montant*) a été fixé de façon méthodologique pour respecter l'exercice pédagogique demandé ; en conditions réelles d'entreprise, ce seuil serait défini conjointement avec les équipes métier selon un objectif de rentabilité explicite (par exemple le top 20% des clients générant 80% du chiffre d'affaires). Troisièmement, comme évoqué en section 5.2, la variable *Frequence* domine excessivement le modèle prédictif du fait de sa proximité mécanique avec la variable *Montant* utilisée pour construire la cible — un point que j'approfondirais si ce projet devait être poursuivi au-delà du cadre de ce mini-projet.

6. Références

Les références ci-dessous sont classées en deux catégories : les références vérifiées (jeu de données et outils techniques réellement utilisés dans ce projet, dont je peux garantir l'existence), et les références de littérature scientifique récente (2020-2026) identifiées lors de la revue de littérature menée au chapitre 3, format IEEE.

6.1 Jeu de données et outils techniques (références vérifiées)

[1] Chen, D., Sain, S. L., & Guo, K. (2012). Data mining for the online retail industry : A case study of RFM model-based customer segmentation using data mining. *Journal of Database Marketing & Customer Strategy Management*, 19(3), 197–208.

[2] Dua, D., & Graff, C. (2019). UCI Machine Learning Repository — Online Retail Data Set. Irvine, CA : University of California, School of Information and Computer Science. Disponible sur : `https://archive.ics.uci.edu/ml/datasets/Online+Retail`

[3] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn : Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[4] McKinney, W. (2010). Data Structures for Statistical Computing in Python. *Proceedings of the 9th Python in Science Conference* (SciPy 2010), 56–61.

[5] Hunter, J. D. (2007). Matplotlib : A 2D Graphics Environment. *Computing in Science & Engineering*, 9(3), 90–95.

[6] Waskom, M. L. (2021). seaborn : statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.

[7] BAQQASS, S. Support de cours Data Mining, Séances 1 à 4 — Master Big Data, IA & Applications Avancées.

6.2 Littérature scientifique récente (2020-2026)

[8] I. Lewaaelhamd, "Customer Segmentation Using Machine Learning Model : An Application of RFM Analysis," *Journal of Data Science and Intelligent Systems*, vol. 2, no. 1, pp. 29–36, 2024, doi : 10.47852/bonviewJDSIS32021293.

[9] A. Kumar, K. U. Singh, G. Kumar, T. Choudhury, and K. Kotecha, "Customer Lifetime Value Prediction : Using Machine Learning to Forecast CLV and Enhance Customer Relationship Management," in *2023 7th International Symposium on Multidisciplinary Studies and Innovative Technologies (ISMSIT)*, Ankara, Turkiye, 2023, pp. 1–7, doi : 10.1109/ISMSIT58785.2023.10304958.

[10] R. S. Manikandan, S. K. Sundar, J. J. Amalraj, et al., "Deep learning-driven customer segmentation model for online retail industry based on extended RFM model," *Discover Computing*, vol. 29, p. 507, 2026, doi : 10.1007/s10791-026-10421-5.

[11] N. El Koufi and A. Belangour, "Toward a Responsive System for Precision Marketing Based on RFM Model, Deep Learning and Features Importance Ranking : A Case Study of Morocco," *International Journal of Advances in Soft Computing and Its Applications*, vol. 16, no. 2, p. 19, 2024, doi : 10.15849/IJASCA.240730.02.

Annexes

Annexe A — Glossaire des termes techniques

Terme	Définition
KDD	*Knowledge Discovery in Databases* : processus global en 5 étapes (sélection, prétraitement, transformation, data mining, interprétation) dont le Data Mining n'est qu'une étape.
RFM	Récence, Fréquence, Montant : modèle de segmentation client fondé sur trois indicateurs comportementaux calculés à partir de l'historique d'achat.
MCAR / MAR / MNAR	Trois mécanismes possibles d'apparition des valeurs manquantes (*Missing Completely At Random / At Random / Not At Random*), selon que l'absence dépend ou non d'autres variables ou de la valeur elle-même.
Odds ratio	Rapport de cotes : dans une régression logistique, exprime de combien une variable multiplie la probabilité relative d'appartenir à la classe positive.
AUC	Aire sous la courbe ROC : mesure la capacité d'un modèle à distinguer les deux classes, indépendamment du seuil de décision choisi (0,5 = hasard, 1,0 = parfait).
IQR	Écart interquartile ($Q3 - Q1$) : utilisé pour détecter les valeurs aberrantes via les bornes $[Q1 - 1{,}5 \times IQR\ ;\ Q3 + 1{,}5 \times IQR]$.
Data leakage	Fuite d'information : situation où une information indisponible au moment de la prédiction réelle est utilisée pendant l'entraînement, ce qui gonfle artificiellement les performances mesurées.
One-Hot Encoding	Transformation d'une variable catégorielle nominale en plusieurs colonnes binaires (une par catégorie), afin d'éviter d'introduire un ordre artificiel.

Annexe B — Extraits de code clés

Je reproduis ci-dessous les deux extraits de code que je juge les plus significatifs de ma démarche, déjà présentés dans le notebook joint à ce rapport.

B.1 — Construction de la table client (agrégation RFM), section 4.5 :

```
date_reference = df["InvoiceDate"].max() + pd.Timedelta(days=1)

rfm = df.groupby("CustomerID").agg(
    Recence=("InvoiceDate", lambda x: (date_reference - x.max()).days),
    Frequence=("InvoiceNo", "nunique"),
    Montant=("MontantLigne", "sum"),
    Pays=("Country", "first")
).reset_index()
```

B.2 — Construction de la cible binaire par seuil médian, section 4.6 (même logique que le TP3 du cours) :

```
seuil_vip = rfm["Montant"].median()
rfm["VIP"] = (rfm["Montant"] > seuil_vip).astype(int)
```

Annexe C — Déclaration de travail individuel

Ce mini-projet a été réalisé intégralement par moi Bilal Jellaoui, seul, de la sélection du jeu de données jusqu'à la rédaction finale de ce rapport : prétraitement des données, construction de la table RFM, modélisation prédictive et descriptive, ainsi que la rédaction de l'ensemble des chapitres.